数据规范 / 可复现交付

X射线模拟训练集数据产生要求

独立 FP 生成器 | 执行与验收规范 v1.0

适用交付软件：fp_competition 0.2.1；物理模型版本：0.2.0。

本规范将既定的“100配方×3谱”流程检查要求、2026-10-17审查整改意见，以及后续扩大训练库所需的覆盖设计合并为可执行说明。审查对象的原始数据与原审查记录保留历史身份；新软件生成的数据必须另建版本。

核心原则：每条谱可追溯、整批可复算、标签与输入隔离、工程验证与科学准确度分开。

本规范不是实测方法认证，不构成“95%的独立实测结果含量相对误差≤5%”的达标证明。模拟标签指实际参与计算的组成；生成参数指模型假设，不能自动解释为客户未知仪器的真实条件。

阅读顺序：第2—4页确定范围与标签；第5—8页检查条件与谱；第9—14页按命令生成、校验与复算；第15—19页处理划分、限制、整改与交付。

交付对象：负责生成数据、审查数据、训练数值模型和构建智能体分析流程的团队成员。各成员应使用同一冻结版本的本规范与软件，不能各自解释“全部通过”。

01 适用范围、角色与状态

必须表示本轮交付或验收不可缺少；**建议**表示正式库设计应采用的做法；**候选方案**不构成已经确认的数量或科学性能门槛。

阶段	目的与验收边界
A：小批量流程样例	已约定100种独立采用配方，每种3条谱，共300条。检查结构、完整性、参数记录、可复现及说明一致性。
B：正式合成训练库	先冻结样品范围、目标元素、含量层级、响应配置和划分，再按覆盖矩阵生成。数据量由学习曲线与分层表现决定。
C：独立实测验证	用未参与建库/校正/调参的样品及可信组成评价真实能力；设备、批次和基体的留出须单独设计。

本轮不得把5万条候选预算、所有矿石/土壤覆盖或真实盲测准确度追加为A阶段既定验收条件。未能读取的分享页面内容不作为新增依据。

角色	应完成的事项
生成负责人	冻结配方、条件和种子；执行生成；保存原始输入与软件快照。
数据审查者	在包外输出QC、完整物理重算和问题闭环记录；明确抽查/全量及运行环境。
训练负责人	只向预测模型提供允许的输入；标签用于训练或独立评分，不混入盲测推理输入。
项目负责人	确认研究范围、覆盖表和正式库预算；确认已通过、待补齐、未验证事项。

status=complete仅表示程序生成完成。软件写入acceptance_status=pending_independent_validation；不得把这个字段改成“全部验收通过”替代独立证据。

02 先设计覆盖，再决定规模

正式训练集不能只重复默认配置。当前地质配方以SiO2补足，源为假定Ag靶和49kV，几何/探测器配置也有固定假设；这不代表已经覆盖任意矿石、土壤或未知仪器。

覆盖维度	每批计划必须说明
基体	例如合金、硅酸盐、富铁氧化物分别建表；不把随机氧化物混合物声称为真实矿物总体分布。
含量	缺失、低含量、次量与主量；范围必须结合样品体系，不让全部目标只在同一痕量区间。
元素组合	单独、少量共存、多元素共存；专门安排As/Pb、S/Pb等干扰组合及不同含量比。
激发/响应	源、管压、滤片、能窗、刻度、分辨率、效率、几何、空气路径的合理配置。
信号质量	不同计数水平、弱峰、截窗与有效扰动；未建模效应不得用随意加噪声冒充。
留出	未见配方族、基体或响应配置；记录谁用于训练、谁仅用于最终评价。

A阶段保持100×3=300。B阶段候选预算可取5000种有效配方×5份冻结响应配置×2次计数抽样=50000谱；该数字只是工程预算，不是统计充分性或达标结论。

当前--replicates在每次重复时重新抽取jitter并派生子种子，不能直接把replicates=10解释为“5个相同响应各2次噪声”。若需5×2结构，可使用同一5000配方全集，分别用5份固定profile、关闭jitter、replicates=2生成5批；每批10000谱，恰好达到单批上限。

多批保持同一成分全集和split_seed只是现有同成分划分一致的必要执行方式；集合改变、增加配方、基体留出或近邻隔离时，需要另行统一冻结全库划分。先小规模测运行时间和磁盘需求，不一次盲目生成全部预算。

03 配方、单位与标签

默认32个候选目标为：Na、Mg、Al、Si、P、S、Cl、K、Ca、Ti、V、Cr、Mn、Fe、Co、Ni、Cu、Zn、As、Se、Rb、Sr、Y、Zr、Nb、Mo、Cd、Sn、Sb、Ba、W、Pb。候选目标列表不是32元素实测定量认证。

字段/内容	必须遵守的规则
id	非空、批内唯一，稳定关联配方。谱ID由程序生成，与客户名称隔离。
composition_percent	实际输入的元素质量百分数；保留完整基体，不只保留目标元素。
compounds_percent	化合物质量百分数，先按原子质量分数转元素；不能直接用作元素含量标签。
trace_ppm	mg/kg；10000ppm=1%质量分数。不得将100ppm写成100%或0.1%。
original_percent	换算/闭合策略处理前的元素组成，原值保留。
used_percent	实际进入物理模型的组成；训练、合成评分以此为准。
targets_percent	固定目标列，缺失的合成组分补精确零；单位为元素质量百分数。
provenance	配方来源、原始化合物/ppm、换算、闭合与身份边界。

采用strict时元素总和必须在1e-6个百分点容差内为100%；不满足就拒绝。normalize_explicit必须主动指定，同时保存原始总和及采用值，不能仍以未归一化值给模拟结果评分。

Fe2O3T是总Fe按Fe2O3报出的约定；按化学计量分配O是模型假设，不证明实物铁价态或氧含量。H/C/N/O可影响基体吸收与散射，本版不产生其低于1keV的荧光，不能把它们列为直接荧光定量目标。

精确零表示合成配方没有加入该元素，不等于真实样品未检出或不存在。来源未给值、低于限值和真实未检出必须与零分开。公开参考组成重建保留原来源身份，不称实测谱或完整认证真值。Als/Alt等非元素字段须明确映射，不能静默相加。

04 激发、时间与样品条件

下列字段来自本版Profile。每条truth和full必须保存实际采用的完整profile，不能只存扰动范围或配置名称。所有数值都要有单位；缺少实测来源时明确标为模型假设。

字段组	字段、单位与解释
激发源	target：靶元素；voltage_kV：管压kV；tube_line_fraction：假定靶线比例。
管流	current_uA、reference_current_uA：μA；模型以二者比值缩放曝光。
时间	live_time_s：活时间s。没有实时间、死时间模型时不能补写实测值或宣称已校正。
入射通量	incident_photons_s：源侧滤片后、所设外部入射空气路径之前的光子率；绝对值未校准。
源侧吸收	tube_be_um：Be管窗μm；filter_Al_um：Al滤片μm。滤片在当前源模型中主要改变归一化谱形。
样品厚度	mass_thickness_g_cm2：质量厚度g/cm²；不等于质量g。其换算应有密度/厚度或几何依据。
几何	detector_distance_cm、detector_area_cm2；incident_angle_deg、exit_angle_deg、scatter_angle_deg。
空气	incident_air_path_cm、exit_air_path_cm：cm；air_density_g_cm3：g/cm³，干空气近似。
积分	source_step_keV：入射积分步长keV；secondary_layers：质量深度层数。

源能量网格从1keV延伸到管压，与探测器输出能窗分开。输入管压高于输出窗上限不代表高能入射光被漏算。吸收边在源积分分段中处理；原子截面与源谱近似的科学不确定性仍需独立评价。

不得把管流、光子率、时间与任意归一化系数重复相乘。空气路径=0只表示模型没有施加该外部空气路径，不能据此声明用户设备处于真空。样品水分、粒度、表面粗糙度和矿物不均匀性当前未单独建模。

05 探测器、刻度与模型状态

字段组	字段、单位与规则
输出轴	channels：64—8192个通道；gain_keV_channel：keV/道；zero_keV：第0通道中心能量keV。
分辨率	noise_fwhm_eV：电子噪声FWHM/eV；fano_factor：无量纲；pair_creation_eV：成对能量eV。
效率近似	detector_si_um：Si厚度μm；detector_be_um：Be窗口μm；有效面积和距离参与几何响应。
逃逸峰	escape_fraction：有效比例；从主信号扣除后移位，非实际晶体结构的反演结果。
人工本底	background_counts_channel：每道期望计数。它在响应记账后另加，不计入截窗前物理信号。
物理开关	secondary、scatter必须是真布尔值，控制二次荧光和散射计算；关闭时保留限制说明。
校准状态	calibration_status必须为assumed_unverified；本版拒绝用配置字段自行宣称已硬件标定。
软件/物理版本	交付软件0.2.1；物理求解模块0.2.0。用源码哈希区分身份，不只看版本字符串。

每个通道中心为E_i=zero+gain×i，i从0至channels−1。左边界为zero−gain/2，右边界为zero+gain×(channels−1/2)。必须区分通道中心范围与积分窗边界。

扰动刻度后，每条谱有自己的能窗；不能把默认配置的一个固定窗口用于整批描述。软件在truth/full中写energy_window，并在manifest/自动README中汇总各中心与边界的最小/最大值。

element_support只检查激发、窗口和假定响应。其“结构支持”不是检出、可识别或可定量结论；1%严重衰减提示阈值是启发式标记。Na/Mg对空气与低能响应敏感，在气氛和窗口未验证前不得承诺可靠定量。

06 盲输入与完整结果的数据契约

盲输入只允许五个字段。不要向盲输入加入能量轴、配方、标样编号、profile、随机种子、来源说明或能直接暴露标签的信息。

blind_inputs字段	类型与约束
axis	固定字符串channel。
signal_unit	固定字符串counts，表示本程序生成的合成计数。
synthetic	必须为true。
x	长度channels；整数序列0…channels−1。
counts	同长度非负整数；不是计数率，也不是归一化信号。

full_results主要字段	必须保存的内容
record_id、schema、版本	唯一谱ID、格式、软件版本、physical_model_version与xraylib版本。
channel、energy_keV	通道与模型真值能量轴；能量轴只作内部真值。
counts、expected_counts	加噪声后的计数与加噪声前期望值。
components_expected_counts	六类物理/人工分量，逐通道与期望谱一致。
profile、composition	全部实际条件；原始/采用组成、单位与闭合记录。
lines	元素、跃迁名称、能量、一次/二次发射贡献；发射贡献不是已探测计数。
losses与窗口	detected_signal_before_window_counts、outside_window_counts、energy_window。
provenance与状态	source_provenance、element_support、warnings、seed、poisson、synthetic=true、hardware_validated=false。

JSON中不允许NaN/Infinity；科学计数法溢出为无穷也必须拒绝。所有谱/分量长度一致且数值有限。full和truth的组成、profile、种子、来源与warnings应一致；full额外包含基体元素的support记录是允许的范围差异。

07 六类分量与窗口损失的正确解释

分量名称	期望计数的含义
primary	一次荧光经效率、出射空气、展宽、逃逸扣除和截窗后的计数。
secondary	一代再激发荧光采用同样响应处理后的计数；不是完整高阶荧光求解。
rayleigh	假定几何下的单次相干散射响应。
compton	单次非相干散射响应；未精细建模束缚电子轮廓和多次散射。
escape	从物理主信号扣出再移位的逃逸分量，不是凭空增加的计数。
background	人工每道期望本底，最后加入；不能当作实测本底或已标定背景。

逐通道检查：expected_counts = primary + secondary + rayleigh + compton + escape + background。

窗口账目检查：detected_signal_before_window_counts ≈ sum(expected_counts − background) + sum(outside_window_counts)。这里的“截窗前”已包含探测效率和出射空气的衰减，不是样品发射前或源端光子总数。

源积分覆盖到管压；荧光与离散化散射谱都经过deposit，计算其入窗高斯积分及窗外份额。因此窗外损失不仅是峰尾，也包含线中心或散射能量点完全位于窗外的信号。它不包括效率/空气吸收前被衰减掉的光子，也不包括人工本底。

若报告比例，必须写分母。本版window_loss_fraction定义为sum(outside_window_counts)/detected_signal_before_window_counts，按每条谱计算，再报告整批最小/最大值。分母为0时不计算比例，不以任意常数替代。

浮点账目容差采用rtol=1e−12、atol=1e−8 counts。闭合仅证明实现中的账目自洽，不证明物理近似正确、绝对效率已校准或真实含量准确。禁止继续沿用无脚本支持的“静默损失”比例。

08 数据包目录与身份管理

每个新版本使用新的输出目录；拒绝覆盖已有数据集。原审查的300谱和README保持原样，修订结果另存，避免抹去审查证据。

```
dataset-v2/
  blind_inputs/S000001.json ...
  full_results/S000001.json ...
  truth.jsonl
  manifest.json
  integrity.json
  README_dataset.md
  inputs/samples.json
  inputs/original_samples.json
  inputs/original_profile.json
  inputs/original_jitter.json
  inputs/original_design_ranges.json
  configs/profile.json
  configs/jitter.json
  reproducibility/recipe.json
  reproducibility/environment.json
  reproducibility/requirements-lock.txt
  reproducibility/generator/fp_competition/...
```

original_*只在CLI提供了对应文件时复制。GUI/API至少封存实际样本和配置，但不能补造未提供的原始文件或设计命令。源文件可从truth重建时，必须标注“重建件”及来源哈希，不能冒充队友最初生成的原件。

QC日志、物理重算报告、问题闭环表及ZIP旁的校验文件写在封存目录外。使用python -B执行包内工具，避免往源码快照写pycache；不要把生成日志随手放入封存包导致清单失配。

每批包含全部运行源码、QC与重算入口、实际环境锁文件。无需交付虚拟环境二进制目录；安装步骤和Python版本必须明确。外部原子数据通过锁定的xraylib依赖获得，不能遗漏依赖后声称离线即可在任意新电脑运行。

09 清单、哈希与证据链

位置/字段	意义
manifest.records[].file	该条盲输入的相对路径。
blind_input_sha256	盲输入文件字节的SHA-256。
sha256	兼容旧字段，仍明确等于blind_input_sha256。
full_results	完整结果相对路径。
full_results_sha256	完整结果的独立SHA-256，不能拿盲输入哈希代替。
family、split、id	组成族、归属与谱ID；须与truth和重新规划结果一致。
source_samples_semantic_sha256	样本列表经约定JSON序列化的语义摘要；与原始文件字节哈希不同。
physics_core_sha256	本批源码快照core.py的字节摘要。
integrity.json	覆盖truth、manifest、输入、配置、源码、文档等所有其他封存文件。

integrity.json自身排除，避免自引用。不得把文件集合增加/删除后仍称原清单有效。哈希路径使用相对POSIX路径；绝对路径、上级目录跳转和指向包外的链接必须拒绝。

原始输入的字节副本与解析后样本都保留：前者证明交付的输入文件快照，后者证明实际送入模型的值。整批语义摘要不能代替每份完整结果的字节摘要。

修改后的源码与基准应有差异说明。0.2.1保留core.py、minerals.py、robustness.py的修订前字节，预期摘要见physics_baseline.json；版本与封存/QC代码另存。此基线证明工作区模块保留，不证明此前缺失的队友源码原本是什么。

哈希只证明与记录快照一致，不证明来源真实性或科学准确度。最终ZIP用外部.zip.sha256记录自身摘要，不把ZIP哈希写回已经封存的内部文件形成循环。

10 三类种子与重复样本

种子/参数	实际控制范围
design或design-mineral的--seed	配方抽样；原设计JSON保存seed和范围配置。
batch的--seed	响应参数扰动和每条谱子种子的派生；扰动字典的顺序影响抽样序列。
batch的--split-seed	组成族划分；若省略，沿用批次seed以兼容旧行为。
每条truth/full中的seed	在给定期望谱下抽取该条Poisson计数。
--replicates	每个输入配方的重复次数，每次重新抽扰动并派生子种子。

同配方3条不是“同seed重放3次”，而是同批次随机过程派生的不同子种子和相应条件。同一配方的期望谱在响应变化时也会变化，不仅是噪声变化。

仅在组成、profile、物理算法和版本固定时，单独改变单谱seed才只改变计数抽样。改变批次seed不能被描述为“仅改变Poisson噪声”；默认情况下还改变划分，显式固定split_seed后才将划分随机源分离。

复现必须保存样本顺序、扰动字段顺序、全部配置、批次种子、划分种子、子种子、闭合策略与目标列表。软件记录NumPy默认位生成器名及实际依赖环境。仅记一个随机种子不够。

固定profile并关闭jitter时，重复谱才共享同一个响应条件；不同噪声重复仍属于同配方组。不能跨集合，也不能将3条噪声重复计为3个独立物理样品。多次生成的S000001编号需要批次命名空间，合库时不能直接覆盖同名文件。

11 从冻结输入到标准生成

在fp_competition目录操作；选择与已冻结依赖兼容的Python版本，建立专用虚拟环境。下面是可执行命令模板，实际路径写入运行日志，所有输出使用新名称。

```
python -m venv .venv
.venv/Scripts/python.exe -m pip install -r requirements-lock.txt
.venv/Scripts/python.exe -B app.py design-mineral --ranges mineral_design_ranges.json --count 100 --out mineral_100.json --seed 20261017
```

批量命令中保留全部目标、设计配置、基准响应和扰动文件：

```
.venv/Scripts/python.exe -B app.py batch --samples mineral_100.json --profile default_profile.json --jitter mineral_jitter_example.json --design-ranges mineral_design_ranges.json --replicates 3 --seed 20261017 --split-seed 20261017 --targets Na Mg Al Si P S Cl K Ca Ti V Cr Mn Fe Co Ni Cu Zn As Se Rb Sr Y Zr Nb Mo Cd Sn Sb Ba W Pb --out dataset-v2
```

--design-ranges只负责封存所提供的设计配置，不自动证明它就是产生输入配方的文件。设计文件自身的seed/design_spec、原始文件副本和样本语义摘要应共同核对；若由人工配方输入，则说明设计过程。

程序先校验样本、目标、扰动和全部抽样profile，再创建新目录；计算期间status=running，失败为failed_partial，完成为complete。failed_partial不能被当作可训练的完整批次。禁止为“跑通”而静默裁剪参数、补造组成或删除失败记录。

GUI批量入口同样保存完整数据包，但CLI更便于准确交付原始文件与命令。正式批次建议使用CLI。单批最多10000条；需要更大数据时应先解决全库划分、批次ID与存储预算，而不是直接多次运行后随意拼接。

12 独立QC：必须全量遍历

使用交付包中的源码快照和实际依赖，不仅查看目录是否存在。执行audit会遍历全部记录，报告写在封存目录外：

```
python -B <包内快照app.py> audit --dataset <数据集目录> --out <包外qc.json>
```

检查组	验收条件
文件/清单	完整性清单的文件集合及每份哈希匹配；300盲输入、300完整结果、300truth记录一一对应。
输入隔离	盲输入严格五字段，无能量、种子、来源、条件或含量泄漏。
数组	长度与通道数一致；计数非负整数；所有期望谱/分量数值有限非负。
跨文件	counts、profile、seed、组成、来源、warnings一致；不存在重复谱ID。
标签	目标列与实际used_percent一致，包含精确零；原始组成按策略复算一致；基体保留。
分量/损失	六分量逐道求和等于期望；截窗前后信号在容差内闭合。
刻度	能量轴与profile相符；中心/边界、每条窗口与整批汇总正确。
随机过程	按记录expected和子种子重放Poisson；按批次recipe重放扰动/子种子/划分。
版本/分组	源码快照核心摘要及物理模块基线一致；同组成族不跨集合。

数值标准：组成总和容差1e-6个百分点；数组/计数账目rtol=1e-12、atol=1e-8 counts。计数数组和离散身份字段要求一致，不以浮点容差容忍少一个计数或错一个ID。

QC输出passed仅表示这些工程检查通过，报告明确complete_physics_recalculation=false。QC必须能拒绝人为篡改：改变完整结果、泄漏标签、修改分量、跨文件不一致或路径越界都不应被漏过。重新计算哈希也不能掩盖语义不一致。

13 完整物理重算与打包

Poisson重放只使用已有期望谱，不能证明期望谱的物理计算可复现。完整重算必须重新调用core.simulate，从原始组成和实际profile重新计算期望谱、六类分量、谱线、损失与最终计数。

```
python -B <包内快照app.py> replay --dataset <数据集目录> --out <包外replay.json>
```

默认重算全部记录。--limit N只检查前N条；报告标scope=subset和complete_physics_recalculation=false，不能写“整批完整复现”。QC失败或运行核心摘要不同，重算工具拒绝继续，要求使用交付快照。

同环境要求计数逐道一致，期望谱和各物理量按明示容差比较；报告最大数组绝对差异、错误列表、环境一致性及重算数量。environment.json还记录数值线程环境变量；复现时按记录在进程级设置，不必改系统配置。跨环境数值匹配可报告passed_with_environment_differences，但必须保留差异，不能升级为同环境严格复现。

文件逐字节相同、随机抽样相同、完整数值相同是不同检查。软件不以重新序列化JSON的字节摘要相同代替物理重算；时间、元数据与格式变化也不能被用来掩盖实际数值差异。源码哈希只能核实快照，不能恢复缺失的历史修改源码。

```
python -B <包内快照app.py> pack --dataset <数据集目录> --out <包外dataset-v2.zip>
```

pack先执行QC，失败则拒绝打包；通过后建立ZIP并做CRC检查，外部写.zip.sha256。pack不自动完成全物理重算，replay报告是单独验收材料。

若重算发现差异，不可直接覆盖旧数据或放宽容差直到通过。先归因于环境、输入、源码、抽样或物理实现，再提交修订版及差异记录。保留原失败报告，重新评审后闭环。

14 数据划分与训练信息边界

当前软件按实际采用组成的精确摘要分族，再以划分种子排序，近似70/15/15分配。至少3个组成族时保证三集合有记录；100族×3条的既定小样例通常对应210/45/45条。

情况	应执行的隔离
同配方不同噪声/响应	全部保持同组，避免记住相同标签和近似形状。
同原谱的平滑/展宽视图	保留原谱父ID，不能当独立样本跨组。
真实样品重复测量	按实体样品/制样批次分组，不仅看文件名。
未见响应/设备	整份配置或设备留出，需要单独划分设计；现有随机同组成划分不自动实现。
未见基体/配方邻域	冻结基体或配方族级留出，不能仅比较完全相同的哈希。
多批合库	统一命名空间、全库去重和分组；不同成分全集即使seed相同也可能改变划分。

训练期间可关联truth取标签；推理/盲测只读blind_inputs；评分程序单独读truth。full中的真实模拟能量轴、profile、配方来源及无噪声分量属于内部真值，不能暗中作为未知条件任务的输入特征。

组成存在标签与“谱中已检出”分开：正含量也可能受低计数、截窗、重叠和吸收影响而不可辨。不能用模拟配方是否非零直接给实测检出结论。

评价应按元素、浓度、基体和响应分层，包括误报、漏报、无法报告比例与含量误差；不能只给总体R^2或谱相似度。独立实测95%/5%目标另需可信实物组成、条件完整的对照和冻结的开发方案。

15 已知模型限制与Ba案例

本版计算均匀平板近似、一次荧光、一代再激发、固定观察角单次散射、假定源谱和Si探测器响应。独立原子数据不等于完整仪器数字孪生；增加样本数量不会消除共同的模型误差。

问题	允许陈述	不允许直接推断
某谱线中心在窗外	指明元素、线系、能量、窗口和剩余可用信息。	整个元素一定无法推断含量。
Ba的K系超窗	当前谱缺少该K系信息；检查保留的L系及相关M线记录。	Ba一定不可定量或一定可定量。
窗外账目闭合	响应计数账目在规定容差内一致。	源端光子守恒、绝对通量正确或实测准确。
element_support有可用线	给定假设下具备激发/记录的结构条件。	已达到检出限、已消除重叠或误差≤5%。
公开组成重建	明确来源、选择了哪些组分、怎样闭合及其假设。	原材料全部组成已知或已测得其真实XRF谱。

原300谱审查记录：207条含Ba，Ba K线中心约31.817—37.2609keV，位于本批记录窗外；它们保留窗内Ba L线，完整记录也有M线。该事实仅属于原审查批次，其他配置必须重新统计。

当前未验证真实设备效率/刻度、死时间/堆积、复杂多层、粗糙度、粒度、水分、矿相与多次散射等影响。外部空气当前只施加衰减，不能因此宣称完整建模了空气散射或Ar荧光。不得用任意噪声模拟这些效应后称“已覆盖”。

需要独立模拟器或实测参照检查模型偏差；即使对照一致，也须明确比较对象和范围，不能把对一个样品/条件的结果泛化为所有元素与基体。

16 审查意见的整改对应表

本页将2026-10-17审查的五类问题变为交付要求。不是替原包补写“已通过”，而是要求修订包提供新证据。

审查问题	新软件/交付要求	复核证据
缺修改版生成器/QC/原始输入	自动封存实际源码、采用样本、CLI原文件、依赖环境、recipe；重建件明确标注。	核实文件存在；独立安装/运行；源码差异及保护模块摘要。
完整结果缺独立哈希	每条盲输入和full各自SHA-256；全包清单排除自身；ZIP外部摘要。	全量重算文件哈希；改动一个full必须失败。
seed说明错误	区分设计种子、批次种子、子种子和可分离split_seed；重复含义准确。	按recipe重放扰动/子种子/划分；Poisson重放与物理重算分别报告。
固定窗口和损失解释错误	每条中心/边界及整批统计；明确窗外账目和比例分母。	从profile独立核算窗口；六分量和窗外计数闭合；不可沿用无依据比例。
Ba结论过度	只描述K系信息缺失及L/M剩余信息；定量能力待独立评估。	逐谱检查元素/线系/能量/窗口，保留适用限制。

每个问题建立闭环行：问题编号、修改文件、修改内容、证据路径/哈希、复核范围、结果、未验证事项。结果使用“已通过、待补齐/未通过、未验证”三类，避免用一个通过状态覆盖所有层次。

缺失的历史源码不能由新版软件“补证”为当时未改核心。当前源快照、字节一致基线和新数据复算只能证明本轮交付。原审查批次若需完整重算，必须明确采用哪个核心、哪个环境及哪些重建输入，另行报告与旧数据的差异。

17 交付、验收和变更清单

交付项	提交前检查
冻结需求	阶段、目标列表、样品范围、覆盖矩阵、参数依据与数量预算明确。
数据本体	blind/full/truth数量对应；核心标签、O等基体、完整条件和来源保留。
输入与软件	原始或明确标记的重建配方、配置、完整生成器及QC/replay入口可用。
环境与命令	Python版本、实际依赖锁、设计/生成/QC/重算/打包命令、终端日志。
工程报告	包外QC及全量物理重算报告；若仅抽查，明确写抽查数量，不能代替全量验收。
校验与文档	双文件哈希、全包清单、准确README、ZIP及外部摘要。
整改闭环	对照原审查逐项给证据与未验证边界；保留原始交付和失败记录。

推荐验收结论模板：“N种独立采用配方、M条谱；全量文件/标签/QC检查结果为……；完整物理重算覆盖……条，环境……；待补齐……；真实定量准确度未验证。”

“仅Poisson复现”“只查了几个full”“哈希一致”“生成器测试通过”“ZIP可解压”均不能单独替代完整验收。相反，尚未完成真实准确度验证不妨碍将合格合成数据用于明确范围内的预训练与方法研究。

变更程序、数据库、配置、配方、划分或标签定义时都建立新版本；先保留旧包，再生成新包、重建哈希和执行相应验证。修正文档也会改变快照，应重封存修订版。不得为了报告好看删除难例、隐去失败或把假设改写成实测条件。

客户报告可以简洁，但内部始终保留计算链、候选条件与校正记录。对于多组相容解释，保留歧义和范围，不把最近邻谱的条件当成客户设备的真实条件。

18 依据、格式示例与使用边界

本轮验收依据：此前100配方×3谱约定、本地2026-10-17《流程检查样例数据集审查》及软件0.2.1实际行为。未读取成功的分享链接不增加要求。所有后续正式库数量、设备范围及性能阈值应另行冻结。

最小manifest记录示例（摘要值为占位示意，不可作为真实校验值）：

```
{
  "id": "S000001",
  "file": "blind_inputs/S000001.json",
  "blind_input_sha256": "<64位十六进制摘要>",
  "sha256": "<与blind_input_sha256相同>",
  "full_results": "full_results/S000001.json",
  "full_results_sha256": "<完整结果的独立摘要>",
  "family": "<采用组成族摘要>",
  "split": "train"
}
```

技术参考入口：

• xraylib官方API：github.com/tschoonj/xraylib/wiki/The-xraylib-API-list-of-all-functions。单位、截面、独立跃迁及化合物解析依据；不是硬件校准。

• XMI-MSIM官方User guide：github.com/tschoonj/xmimsim/wiki/User-guide。组成、几何、激发、吸收层和响应需分别记录；本版未因此获得蒙特卡罗验证。

• Amptek C-Series Low Energy X-Ray Windows官方说明：amptek.com。轻元素对窗口和空气敏感；厂商典型值不替代用户设备实测参数。

• USGS BHVO-2 / BCR-2 June 2022信息表：软件public_data保存来源和哈希。文献汇总估计与显式重建，非新增实测谱。

更多文献访问范围与实现取舍见软件REFERENCES.md。本规范不通过下载文献或增加模拟数量，授予真实含量准确度、检出限或设备校准身份。